

# **Contributions aux communications multi-vues pour l'apprentissage collaboratif**

---

Denis Maurel

10 Décembre 2018

Introduction

Clustering collaboratif incrémental

Optimisation de paramètres pour le clustering collaboratif

Système de reconstruction collaboratif

Conclusion et Perspectives

## Introduction

---

L'apprentissage machine (ou Machine Learning en anglais) est le domaine de recherche regroupant les algorithmes et les méthodes permettant **d'apprendre automatiquement** un résultat à partir d'un ensemble de données, aussi appelés **individus**. Les trois principales problématiques du Machine Learning sont:

L'apprentissage machine (ou Machine Learning en anglais) est le domaine de recherche regroupant les algorithmes et les méthodes permettant **d'apprendre automatiquement** un résultat à partir d'un ensemble de données, aussi appelés **individus**. Les trois principales problématiques du Machine Learning sont:

- **La classification**: apprentissage des correspondances entre une donnée et son label.

L'apprentissage machine (ou Machine Learning en anglais) est le domaine de recherche regroupant les algorithmes et les méthodes permettant **d'apprendre automatiquement** un résultat à partir d'un ensemble de données, aussi appelés **individus**. Les trois principales problématiques du Machine Learning sont:

- **La classification**: apprentissage des correspondances entre une donnée et son label.
- **Le clustering**: détection de groupes d'individus similaires.

L'apprentissage machine (ou Machine Learning en anglais) est le domaine de recherche regroupant les algorithmes et les méthodes permettant **d'apprendre automatiquement** un résultat à partir d'un ensemble de données, aussi appelés **individus**. Les trois principales problématiques du Machine Learning sont:

- **La classification**: apprentissage des correspondances entre une donnée et son label.
- **Le clustering**: détection de groupes d'individus similaires.
- **L'apprentissage par renforcement**: apprentissage d'un comportement permettant à un modèle de réagir à un environnement dynamique.


L'apprentissage machine (ou Machine Learning en anglais) est le domaine de recherche regroupant les algorithmes et les méthodes permettant **d'apprendre automatiquement** un résultat à partir d'un ensemble de données, aussi appelés **individus**. Les trois principales problématiques du Machine Learning sont:

- **La classification**: apprentissage des correspondances entre une donnée et son label.
- **Le clustering**: détection de groupes d'individus similaires.
- **L'apprentissage par renforcement**: apprentissage d'un comportement permettant à un modèle de réagir à un environnement dynamique.



# Clustering

- Tâche d'apprentissage **non supervisée** consistant à rassembler des groupes d'individus (a.k.a. clusters) de sorte à **maximiser la similarité intra-groupe** et à **minimiser la similarité inter-groupes**.



## Clustering: similarité entre individus

- La notion de **similarité** est souvent assimilée à la notion de **distance**.
- La similarité doit être **adaptée à la nature des données**.

Euclidienne	$\ a - b\ _2 = \sqrt{\sum_i (a_i - b_i)^2}$
Manhattan	$\ a - b\ _1 = \sum_i  a_i - b_i $
Maximum	$\ a - b\ _\infty = \max_i  a_i - b_i $
Mahalanobis	$\sqrt{(a - b)^T S^{-1} (a - b)}$
Hamming	$\text{Hamming}(a, b) = \sum_i (1 - \delta_{a_i, b_i})$

**Table 1:** Exemples de distances

## Clustering: types de partitions

Après un clustering, on obtient une partition de l'espace ainsi que les appartenances des individus à chaque groupe de cette partition. Ces appartenances peuvent être **dures**, **molles** ou **floues**.

	c <sub>1</sub>	c <sub>2</sub>	c <sub>3</sub>
x <sub>1</sub>	1	0	0
x <sub>2</sub>	0	1	0
x <sub>3</sub>	0	0	1
x <sub>4</sub>	0	0	1

**(a)** Clustering dur

	c <sub>1</sub>	c <sub>2</sub>	c <sub>3</sub>
x <sub>1</sub>	1	1	0
x <sub>2</sub>	0	1	1
x <sub>3</sub>	0	0	1
x <sub>4</sub>	0	0	1

**(b)** Clustering mou

	c <sub>1</sub>	c <sub>2</sub>	c <sub>3</sub>
x <sub>1</sub>	0.9	0.1	0
x <sub>2</sub>	0	0.8	0.2
x <sub>3</sub>	0	0.3	0.7
x <sub>4</sub>	0	0	1.0

**(c)** Clustering flou

**Table 2:** Les trois principaux types d'appartenances à des clusters

On peut regrouper les algorithmes de clustering en sous-catégories suivant l'approche qu'ils utilisent:

- **Méthodes hiérarchiques:** création d'un arbre de correspondance entre les individus (Agglomerative method).
- **Méthodes de quantification de vecteurs:** définition d'individus prototypes pour synthétiser les individus en entrée (K-Means, SOM).
- **Méthodes de densité:** estimation des clusters suivant les zones les plus densément peuplées de l'espace d'entrée (DBSCAN).
- **Méthodes stochastiques:** création de modèles probabilistes définissant la probabilité d'appartenance d'un individu à un cluster donné (GMM).

On peut regrouper les algorithmes de clustering en sous-catégories suivant l'approche qu'ils utilisent:

- **Méthodes hiérarchiques:** création d'un arbre de correspondance entre les individus (Agglomerative method).
- **Méthodes de quantification de vecteurs:** définition d'individus prototypes pour synthétiser les individus en entrée (K-Means, SOM).
- **Méthodes de densité:** estimation des clusters suivant les zones les plus densément peuplées de l'espace d'entrée (DBSCAN).
- **Méthodes stochastiques:** création de modèles probabilistes définissant la probabilité d'appartenance d'un individu à un cluster donné (GMM).

Apparition d'un nouveau contexte: **un même ensemble d'individu** est décrit dans plusieurs base de données indépendantes appelées **vues**.

**Problème:** comment obtenir un clustering de cet ensemble d'individus ?

Deux approches:

Apparition d'un nouveau contexte: **un même ensemble d'individu** est décrit dans plusieurs base de données indépendantes appelées **vues**.

**Problème:** comment obtenir un clustering de cet ensemble d'individus ?

Deux approches:

- **Coopérative:** chaque vue effectue un clustering de ses données locales avant de transférer ses résultats à une entité tiers qui devra fusionner les résultats.

Apparition d'un nouveau contexte: **un même ensemble d'individu** est décrit dans plusieurs base de données indépendantes appelées **vues**.

**Problème:** comment obtenir un clustering de cet ensemble d'individus ?

Deux approches:

- **Coopérative:** chaque vue effectue un clustering de ses données locales avant de transférer ses résultats à une entité tiers qui devra fusionner les résultats.
- **Collaborative:** chaque vue effectue un premier clustering local, puis le modifie en fonction des résultats obtenus par les autres vues.



Apparition d'un nouveau contexte: **un même ensemble d'individu** est décrit dans plusieurs base de données indépendantes appelées **vues**.

**Problème:** comment obtenir un clustering de cet ensemble d'individus ?


Deux approches:

- **Coopérative:** chaque vue effectue un clustering de ses données locales avant de transférer ses résultats à une entité tiers qui devra fusionner les résultats.
- **Collaborative:** chaque vue effectue un premier clustering local, puis le modifie en fonction des résultats obtenus par les autres vues.

## Clustering collaboratif: définition


Le **clustering collaboratif** est un domaine récent désignant l'ensemble des méthodes permettant à **plusieurs algorithmes de clustering** opérant sur des **sources de données différentes** de collaborer pour **améliorer localement** leurs résultats.

- Les algorithmes utilisés peuvent être **différents**.
- Les vues doivent partager soit leurs descripteurs (clustering vertical), soit **leurs individus** (clustering horizontal) pour pouvoir être comparées.



**Figure 1:** Illustration du principe de clustering collaboratif horizontal

## Clustering collaboratif: processus



**Figure 2:** Processus de clustering collaboratif

Définition du critère collaboratif:

$$\begin{aligned} Q^i &= \alpha_i Q_{\text{local}}^i(v_i) + Q_{\text{collab}}^i(v_i, v_{j \neq i}) \\ &= \alpha_i Q_{\text{local}}^i(v_i) + \sum_{j \neq i} \beta_j^i C_j^i(v_i, v_j) \end{aligned}$$

- $Q_{\text{local}}^i$  est généralement basé sur **le critère de l'algorithme local** à optimiser.
- $Q_{\text{collab}}^i$  se base sur **l'échange d'information entre vues**, typiquement les appartenances des individus aux clusters respectifs de chaque vue.  $C_j^i$  représente **la dissimilarité** entre les vues  $i$  et  $j$ .
- $\alpha_i$  et  $\beta_j^i$  sont définis **à la main**. L'approximation  $\forall j, \beta_j^i = \alpha_i^2$  est parfois utilisée car donnant de bons résultats en pratique.


## **Clustering collaboratif incrémental**

---

Objectif du clustering collaboratif: définir un ensemble de clusters suivant **la distribution** des données fournies en entrée.

**Problème:** il arrive que cette distribution **évolue au cours du temps**

**Exemple:** évolution du régime alimentaire d'un individu ou de la répartition des salaires à l'échelle d'une population.



Utilisation du clustering **incrémental**: les clusters sont appris au cours du temps afin de **s'adapter** aux éventuels changements de distribution. On utilise les  $N_{\text{batch}}$  derniers individus comme échantillon d'apprentissage.

Définition d'une méthode de clustering incrémental:

Définition d'une méthode de clustering incrémental:

- Choix de la **méthode de clustering**



Définition d'une méthode de clustering incrémental:

- Choix de la **méthode de clustering**
- **Adaptation de la méthode de clustering** pour de l'apprentissage incrémental


Définition d'une méthode de clustering incrémental:

- Choix de la **méthode de clustering**
- **Adaptation de la méthode de clustering** pour de l'apprentissage incrémental
- **Adaptation du clustering collaboratif** au modèle de clustering obtenu

## Cartes Auto-Adaptatrices (SOM)

Dans notre cas, utilisation des **cartes auto-adaptatrices de Kohonen** (ou Self-Organizing Maps (SOM) en anglais) comme méthode de clustering.

- Méthode à base de **prototypes** (quantification de vecteurs)
- Permet la **visualisation** de données en hautes dimensions
- Notion de **voisinage**: utilisation d'une **fonction de température**.




**Figure 3:** Exemple de SOM


# Cartes Auto-Adaptatrices (SOM)

Fonction de température:  $\lambda(t) = \lambda_{\min} \left( \frac{\lambda_{\max}}{\lambda_{\min}} \right)^{\frac{1}{t}}$

Fonction de voisinage:  $K_{i,j} = \exp \left( -\frac{d_1^2(i,j)}{\lambda(t)} \right)$



**(a)** Température élevée



**(b)** Température faible

Les solutions existantes pour les SOM incrémentales se basent toutes sur l'ajout de prototypes ([Papilinski2012] et [Deng2000]).

Les solutions existantes pour les SOM incrémentales se basent toutes sur l'ajout de prototypes ([Papinski2012] et [Deng2000]).

**Problème 1:** Est-il possible de trouver une solution **conservant la topologie de la carte** ?

Les solutions existantes pour les SOM incrémentales se basent toutes sur l'ajout de prototypes ([Papinski2012] et [Deng2000]).

**Problème 1:** Est-il possible de trouver une solution **conservant la topologie de la carte** ?

**Problème 2:**  $\lambda$  est **dépendante du temps**, ce qui pose problème avec le clustering incrémental.

Les solutions existantes pour les SOM incrémentales se basent toutes sur l'ajout de prototypes ([Papilinski2012] et [Deng2000]).

**Problème 1:** Est-il possible de trouver une solution **conservant la topologie de la carte** ?

**Problème 2:**  $\lambda$  est **dépendante du temps**, ce qui pose problème avec le clustering incrémental.

→ rendre la fonction dépendante des **individus**

$$\lambda(t) = \lambda_{\min} \left( \frac{\lambda_{\max}}{\lambda_{\min}} \right)^{\frac{1}{t}} \rightarrow \tilde{\lambda}(B, W) = \frac{1}{N_{\text{batch}}} \sum_{i=1}^{N_{\text{batch}}} \|x_i - \chi(x_i)\|_2$$
$$K_{i,j}(\lambda(t)) \rightarrow K_{i,j}(\tilde{\lambda}(B, W)) \rightarrow \tilde{K}_{i,j}$$





- **1<sup>ère</sup> contrainte:** des individus correspondants doivent appartenir à des **prototypes correspondants** ou à leurs voisinages proches.

- **1<sup>ère</sup> contrainte:** des individus correspondants doivent appartenir à des **prototypes correspondants** ou à leurs voisinages proches.
- **2<sup>ème</sup> contrainte: même topologie des cartes** pour toutes les vues pour les rendre comparables.

## SOM incrémentale et clustering collaboratif

- **1<sup>ère</sup> contrainte:** des individus correspondants doivent appartenir à des **prototypes correspondants** ou à leurs voisinages proches.
- **2<sup>ème</sup> contrainte: même topologie des cartes** pour toutes les vues pour les rendre comparables.

Adaptation de notre version de SOM incrémentale au clustering collaboratif:

$$\begin{aligned} & Q_{\text{local}}^m(K_{i,j}) / Q_{\text{collab}}^m(\Delta K_{i,j}) \\ \Rightarrow & Q_{\text{local}}^m(\tilde{K}_{i,j}) / Q_{\text{collab}}^m(\Delta \tilde{K}_{i,j}) \\ \Rightarrow & \tilde{Q}_{\text{local}}^m / \tilde{Q}_{\text{collab}}^m \end{aligned} \quad K_{i,j} = \exp \left( -\frac{d_1^2(i,j)}{\lambda(t)} \right)$$

Le nouveau critère dépendant uniquement des  $N_{\text{batch}}$  derniers individus apparus, il est possible d'effectuer un **apprentissage collaboratif incrémental** sur l'ensemble des vues.

Test de notre méthode sur 4 jeux de données différents

- Spambase
- Waveform
- Wisconsin Breast Cancer Diagnosis (WDBC)
- Isolet

**Pureté d'un prototype:** classe majoritaire parmi les individus associés à ce prototype. **Pureté d'une SOM:** pureté moyenne de ses prototypes. **Erreur moyenne de quantification:** distance moyenne entre un prototype et les individus qui y sont associés.

$$qe = \frac{1}{N_{batch}} \sum_{i=1}^{N_{batch}} \|x_i - \chi(x_i)\|^2$$


**Table 3:** Erreur de quantification moyenne pour chaque base de donnée.

	SOM incrémentales	clustering collaboratif incrémental	$\Delta$
Spam Base	0.223	0.203	<b>- 0.02</b>
Waveform	0.197	0.24	<b>+ 0.043</b>
WDBC	0.183	0.18	<b>- 0.003</b>
Isolet	2.61	1.34	<b>- 1.27</b>

- **Score en quantification à long termes comparables:** le clustering collaboratif n'endommage pas les résultats locaux.
- Le clustering collaboratif permet de **limiter l'impact du bruit** dans les vues.

## Expérimentations: résultats sur Isolet

**Figure 5:** Évolution des puretés pour Isolet. Les lignes rouges représentent les SOM incrémentales tandis que les lignes noires représentent les SOM incrémentales collaboratives. Chaque itération correspond à l'arrivée d'une nouvelle donnée




(a)  $N_{\text{batch}} = 10$ , View 1


(b)  $N_{\text{batch}} = 10$ , View 2

(c)  $N_{\text{batch}} = 10$ , View 3

- Les SOM incrémentales collaboratives **apprennent plus vite que les SOM incrémentales seules**: exploitation de l'information via le partage.
- Les SOM collaboratives sont globalement **plus instables** que les SOM incrémentales.



(a)  $N_{\text{batch}} = 10$ , View 3



(b)  $N_{\text{batch}} = 3$ , View 3

**Figure 7:** Évolution des puretés pour Isolet: impact de la taille du batch sur la stabilité de l'apprentissage.

- La stabilité de l'apprentissage **augmente avec la taille du batch**: plus d'informations à exploiter.



## Contributions

- Définition d'une **nouvelle méthode de cartes auto-adaptatives incrémentales**
- Adaptation de la méthode précédente au **clustering collaboratif**
- Analyse de l'impact de **la taille du batch sur la stabilité de l'apprentissage**.

## Contributions

- Définition d'une **nouvelle méthode de cartes auto-adaptatives incrémentales**
- Adaptation de la méthode précédente au **clustering collaboratif**
- Analyse de l'impact de **la taille du batch sur la stabilité de l'apprentissage**.

**Comment déterminer quelles sont les meilleures collaborations inter-vues ?**

## **Optimisation de paramètres pour le clustering collaboratif**

---

Rappel du critère du clustering collaboratif:

$$\begin{aligned} Q^i &= \alpha_i Q_{\text{local}}^i(v_i) + Q_{\text{collab}}^i(v_i, v_{j \neq i}) \\ &= \alpha_i Q_{\text{local}}^i(v_i) + \sum_{j \neq i} \beta_j^i C_j^i(v_i, v_j) \end{aligned}$$

**Objectif:** Apprendre automatiquement les  $\alpha$  et les  $\beta$  en s'affranchissant de simplifications telles que  $\beta = \alpha^2$ .

Nous avons proposé **une nouvelle méthode de pondération** permettant d'apprendre automatiquement les poids fixant **les importances relatives des différents scores**.

La définition des  $\alpha$  et des  $\beta$  passe par la résolution d'un problème sous contrainte. Les contraintes sont les suivantes :

La définition des  $\alpha$  et des  $\beta$  passe par la résolution d'un problème sous contrainte. Les contraintes sont les suivantes :

$$\bullet \beta^* = \operatorname{argmin}_{\beta} \sum_{i \neq j} \beta_{i,j} c_{i,j}$$

## Optimisation de paramètres: définition du problème

La définition des  $\alpha$  et des  $\beta$  passe par la résolution d'un problème sous contrainte. Les contraintes sont les suivantes :

- $\beta^* = \operatorname{argmin}_{\beta} \sum_{i \neq j} \beta_{i,j} c_{i,j}$
- $\forall j \quad \prod_{i \neq j} \beta_{i,j} = 1$

La définition des  $\alpha$  et des  $\beta$  passe par la résolution d'un problème sous contrainte. Les contraintes sont les suivantes :

- $\beta^* = \operatorname{argmin}_{\beta} \sum_{i \neq j} \beta_{i,j} c_{i,j}$
- $\forall j \quad \prod_{i \neq j} \beta_{i,j} = 1$
- $\forall (i, j) \quad \beta_{i,j} > 0$



La définition des  $\alpha$  et des  $\beta$  passe par la résolution d'un problème sous contrainte. Les contraintes sont les suivantes :

- $\beta^* = \operatorname{argmin}_{\beta} \sum_{i \neq j} \beta_{i,j} c_{i,j}$
- $\forall j \quad \prod_{i \neq j} \beta_{i,j} = 1$
- $\forall (i, j) \quad \beta_{i,j} > 0$
- Affranchissement des  $\alpha$ : comme il s'agit de pondérations relatives, on peut fixer  $\alpha = 1$ .

La définition des  $\alpha$  et des  $\beta$  passe par la résolution d'un problème sous contrainte. Les contraintes sont les suivantes :

- $\beta^* = \operatorname{argmin}_{\beta} \sum_{i \neq j} \beta_{i,j} c_{i,j}$
- $\forall j \quad \prod_{i \neq j} \beta_{i,j} = 1$
- $\forall (i, j) \quad \beta_{i,j} > 0$
- Affranchissement des  $\alpha$ : comme il s'agit de pondérations relatives, on peut fixer  $\alpha = 1$ .

**Objectif:** mettre des poids plus élevés sur les meilleurs accords, tout en gardant une certaine partie des vues en désaccord pour faire évoluer l'information

Critère + contrainte d'égalité + contrainte d'inégalité

→ **méthode de Karush-Kuhn-Tucker (KKT)**

$$\mathcal{L}(\beta, \nu, \lambda) = \sum_{j=1}^J \sum_{i \neq j}^J (\beta_{i,j} c_{i,j} - \nu_j \ln \beta_{i,j} - \lambda_{i,j} \beta_{i,j}).$$

$$\frac{\partial \mathcal{L}}{\partial \beta_{i,j}} = 0, \quad \frac{\partial \mathcal{L}}{\partial \nu} = 0, \quad \frac{\partial \mathcal{L}}{\partial \lambda} = 0$$

Après résolution, on obtient:

$$\forall (i, j), \quad i \neq j \quad \beta_{i,j} = \frac{(\prod_{k \neq j} c_{k,j})^{\frac{1}{j-1}}}{c_{i,j}}$$

L'importance d'une vue externe relativement à une vue locale est proportionnelle au rapport entre la moyenne géométrique de toutes les dissimilarités sur la dissimilarité entre les deux vues .

Après résolution, on obtient:

$$\forall (i, j), \quad i \neq j \quad \beta_{i,j} = \frac{(\prod_{k \neq j} c_{k,j})^{\frac{1}{j-1}}}{c_{i,j}}$$

L'importance d'une vue externe relativement à une vue locale est proportionnelle au rapport entre la moyenne géométrique de toutes les dissimilarités sur la dissimilarité entre les deux vues .

→ **plus 2 vues sont similaires, plus elles collaboreront.**

Deux axes d'analyse:

- Analyse de **l'évolution du critère collaboratif** avec et sans apprentissage automatique des poids (critère: différence relative).
- Analyse des **valeurs prises par les  $\beta$**  en fin d'apprentissage. (critère: différences relatives entre les poids).

Deux axes d'analyse:

- Analyse de **l'évolution du critère collaboratif** avec et sans apprentissage automatique des poids (critère: différence relative).
- Analyse des **valeurs prises par les  $\beta$**  en fin d'apprentissage. (critère: différences relatives entre les poids).

Ce que l'on s'attend à trouver:

- Une **amélioration de la valeur du critère collaboratif** grâce à notre méthode
- **L'identification automatique des vues bruitées**, menant à des valeurs de  $\beta$  proches de 0.

Deux axes d'analyse:

- Analyse de **l'évolution du critère collaboratif** avec et sans apprentissage automatique des poids (critère: différence relative).
- Analyse des **valeurs prises par les  $\beta$**  en fin d'apprentissage. (critère: différences relatives entre les poids).


Ce que l'on s'attend à trouver:

- Une **amélioration de la valeur du critère collaboratif** grâce à notre méthode
- **L'identification automatique des vues bruitées**, menant à des valeurs de  $\beta$  proches de 0.


À noter: pour chaque base de données, **une vue entièrement composée de bruit** a été rajoutée pour tester le second point.




**Figure 8:** Différences relatives du critère collaboratif avec et sans optimisation des  $\beta$  tout au long du processus d'apprentissage.



**(a)** Spambase



**(b)** Isolet




**(c)** VHR Strasbourg

- **Amélioration du critère** de manière significative dans la majorité des cas
- Tous les jeux de données **ne sont pas traités de la même manière** (dépend de la quantité et de la qualité de l'informations à partager).


**Figure 10:** Cartes de chaleur des matrices de  $\beta$  pour chaque jeu de données.

$M(i, j)$  correspond à l'importance accordée à la Vue  $j$  par la Vue  $i$ .


Blanc = forte collaboration - noir = faible collaboration - diagonale représente  $\beta = 1$ .



(a) WDBC



(b) Waveform



(c) Isolet

- **Identification des vues bruitées.**
- Apparition de **méta-clusters** (des clusters de clusters). Les vues auront tendance à se regrouper en sous-groupe mutuellement d'accord.

- Proposition d'un **système de pondération automatique des vues externes** pour le clustering collaboratif.
- **Amélioration** de la valeur du critère collaboratif
- **Identification des vues bruitées.**
- **(BONUS)** Apparition de **méta-clusters** de vues


- Proposition d'un **système de pondération automatique des vues externes** pour le clustering collaboratif.
- **Amélioration** de la valeur du critère collaboratif
- **Identification des vues bruitées.**
- **(BONUS)** Apparition de **méta-clusters** de vues


**Est-il possible d'étendre l'idée de collaboration  
à d'autres problèmes que le clustering ?**

# **Système de reconstruction collaboratif**

---




















## Reconstruction collaborative: définition

Comment définir le problème de **reconstruction collaborative** ?

- Application du **paradigme collaboratif** à un autre problème
- Le clustering collaboratif nécessite la **description d'un même individu dans chacune des vues**
- En pratique, les données souvent sont **soit manquantes, soit incomplètes**.

?			?		?						
		?			?			?		?	
	?	?	?	?			?				?
?					?				?	?	

La reconstruction collaborative devrait permettre d'obtenir **une approximation** d'un individu dans une vue connaissant **l'information présente dans les autres vues**.

1. **Compresser et anonymiser** les données
2. **Transférer de l'information** d'une vue externe à une vue locale
3. **Combiner les informations** en provenance de différentes sources

1. **Compresser et anonymiser** les données
2. **Transférer de l'information** d'une vue externe à une vue locale
3. **Combiner les informations** en provenance de différentes sources

Ce que nous proposons:

1. **Des réseaux de neurones** (autoencodeurs).

1. **Compresser et anonymiser** les données
2. **Transférer de l'information** d'une vue externe à une vue locale
3. **Combiner les informations** en provenance de différentes sources

Ce que nous proposons:

1. **Des réseaux de neurones** (autoencodeurs).
2. **D'autres réseaux de neurones** (perceptrons multi-couches).



1. **Compresser et anonymiser** les données
2. **Transférer de l'information** d'une vue externe à une vue locale
3. **Combiner les informations** en provenance de différentes sources


Ce que nous proposons:

1. **Des réseaux de neurones** (autoencodeurs).
2. **D'autres réseaux de neurones** (perceptrons multi-couches).
3. **Une nouvelle méthode de combinaison.**

- Réseau de neurone:  
**approximateur universel  
de fonction.**

- **Backpropagation:**  
Méthode utilisée pour  
**mettre à jour des  
paramètres.**


- L'erreur est propagée **de  
la sortie vers l'entrée** du  
réseau.



# Réseaux de neurones: MLP et autoencodeurs


## Perceptron multi-couches

- entrées et sorties **différentes**
- apprentissage **supervisé**



## Autoencodeur


- entrées et sorties **identiques**
- apprentissage **non supervisé**




# Reconstruction collaborative: rappel

## Rappel de la problématique

- Un individu décrit dans **toutes les vues sauf une**
- Utilisation des informations externes pour obtenir **une approximation locale**



# Reconstruction collaborative: système



**Figure 12:** Architecture d'un système de reconstruction collaborative


# Reconstruction collaborative: système

## Autoencodeurs

- Un par vue: encoder chaque espace
- Rend difficile la reconstruction des données originales sans le décodeur

## Perceptron multi-couches

- Décode les représentations externes
- Passe d'un espace codé à l'espace local




- Pour chaque individu et avec  $N$  vues, on peut avoir jusqu'à  $N - 1$  **reconstructions différentes**.
- Comment les combiner ?

- Pour chaque individu et avec  $N$  vues, on peut avoir jusqu'à  $N - 1$  **reconstructions différentes**.
- Comment les combiner ?
- Habituellement, combinaison **pondérée** des différentes reconstructions.
  - Un scalaire par vue
  - Différentes façons d'apprendre les poids



- Pour chaque individu et avec  $N$  vues, on peut avoir jusqu'à  $N - 1$  **reconstructions différentes**.
- Comment les combiner ?
- Habituellement, combinaison **pondérée** des différentes reconstructions.
  - Un scalaire par vue
  - Différentes façons d'apprendre les poids
- MAIS hypothèse forte: chaque vue contient exactement **la même information** sur chaque descripteur → irréaliste.
- À la place d'un poids unique, nous utilisons un **masque**.


## Reconstruction collaborative: combinaison



**Figure 13:** Pondération par masque (Masked Weighting Method en anglais).

# Reconstruction collaborative: combinaison

- Chaque vue possède  $N - 1$  masques, un par vue externe, utilisés pour **pondérer chaque représentation externe**.
- Chaque masque est entraîné de manière itérative
- **Avantage:** les masques peuvent se concentrer sur **les parties les mieux reconstruites** par la vue externe.



Idée de base pour la mise à jour des poids

$$E_i = \frac{1}{|V_i|} \sum_{x_i \in V_i} \|x_i - \tilde{x}_i\|^2 \quad \text{puis} \quad \frac{\partial E_i}{\partial w_{ij}^k} = 0$$

- $E_i$  = erreur de la  $i$ -ème vue
- $V_i$  =  $i$ -ème vue
- $x_i$  = individu de  $V_i$
- $w_{ij}^k$  =  $k$ -ème coordonnée du masque attribué à la  $j$ -ème vue

Après calcul:

$$w_{ij}^k = \frac{\sum_{x_i \in V_i} x_{ij}^k (x_i^k - \sum_{j' \in [1..N] \setminus \{i,j\}} w_{ij'}^k x_{ij'}^k)}{\sum_{x_i \in V_i} (x_{ij}^k)^2}$$


Après calcul:

$$w_{ij}^k = \frac{\sum_{x_i \in V_i} x_{ij}^k (x_i^k - \sum_{j' \in [1..N] \setminus \{i,j\}} w_{ij'}^k x_{ij'}^k)}{\sum_{x_i \in V_i} (x_{ij}^k)^2}$$

- La mise à jour d'un poids dépend de **tous les autres paramètres**  
→ Définition d'une règle de mise à jour **itérative**.

- Entraînement **séquentiel**
  - les autoencodeurs pour **encoder** les données
  - les perceptrons multi couches pour **reconstruire** les individus
  - les masques pour **combiner** les échantillons reconstruits
- Une vue n'a **jamais** accès aux données originales de deux vues différentes.
  - **autoencodeurs**: données originales locales
  - **perceptrons**: données externes encodées + données originales locales
  - **masques**: échantillons reconstruits + données originales locales

## Reconstruction collaborative: entraînement



**Figure 14:** Apprentissage séquentiel des éléments du système



- Wisconsin Diagnostic Breast Cancer (WDBC)
  - 569 individus
  - 32 descripteurs
- Multi-Features Digital Dataset (MFDD)
  - 2000 individus
    - 76 coefficients de Fourier
    - 216 correlations profile
    - 64 coefficients Karhunen-Love
    - **240 pixels moyennés en fenêtres de  $2 \times 3$**
    - 47 moments de Zernike
- Madelon
  - 4400 individus
  - 20 (utiles) 480 (bruits) variables

- Distance quadratique moyenne







$$\text{MSE}(x, y) = \frac{1}{K} \sum_{i=1}^K (x_i - y_i)^2$$

- Différence relative moyenne

$$\text{MRD}(X, Y) = \frac{1}{K} \sum_{i=1}^K \left| \frac{x_i - y_i}{y_i} \right|$$

- Analyse visuelle d'images reconstruites (MFDD)

# Reconstruction collaborative: résultats




(a) WDBC

(b) MFDD


(c) Madelon

**Figure 15:** Erreur par vue et par jeu de données


# Reconstruction collaborative: images originales



# Reconstruction collaborative: images reconstruites




# Reconstruction collaborative: images améliorables



- Les données sont reconstruites pour **ensuite** être utilisées
- Cas d'application: **la classification** (ici avec des Random Forests)
- Est-ce que les individus reconstruits sont utilisables pour des applications ultérieures ?
- **Critère: différence en classification:** différence entre le score utilisant les données originales et celui utilisant les données reconstruites.

# Reconstruction collaborative: un peu plus loin




**Figure 19:** Différences en classification par vue et par jeu de données

- Résultats **proches des résultats originaux**
- Impact de notre méthode de pondération **dépendant du jeu de données** et **limité**.




# Reconstruction collaborative: efficacité de la MWM

- Nouveau jeu de données **artificiel**: Cube
- 100 individus décrits par 3 descripteurs
- chaque vue est créée en **supprimant** une des dimensions
- **Objectif**: Tester la capacité de la méthode de pondération par masque à **détecter quels descripteurs sont pertinents**.



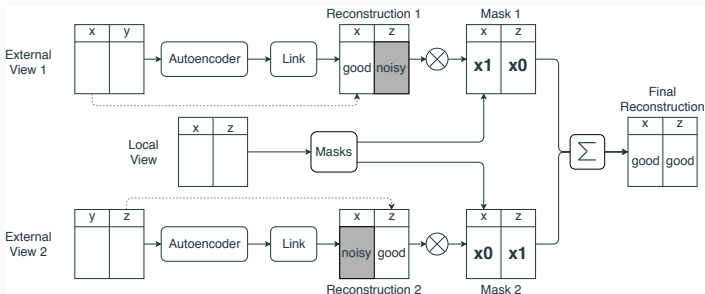
(a) Jeu de données Cube



(b) Projection

## Reconstruction collaborative: efficacité de la MWM

- La méthode de pondération par masque **améliore les résultats en reconstruction**.
- La sélection des features reconstruits **fonctionne t-elle en pratique ?**



**Figure 21:** Combinaison de deux individus partiellement corrects

	Moyenne	Écart type
<b>Descripteur partagé</b>	0.920	0.026
<b>Descripteur non partagé</b>	0.143	0.034

**Table 4:** Moyenne et écart-type des paramètres des masques en fonction du descripteur qu'elles pondèrent

- Les masques arrivent à **cibler les descripteurs partagés** tout en **limitant l'utilisation des descripteurs non partagés**.
- Le faible écart type indique une certaine **stabilité** de la méthode

## Contributions

- Définition d'un nouveau **cas d'application du paradigme collaboratif**.
- Définition d'un système permettant de **reconstruire de manière collaborative** et basé sur des **réseaux de neurones**.
- Définition d'une méthode permettant de **combinaison efficacement un ensemble de reconstructions**.

## Résultats

- Scores **améliorables** en reconstruction.
- Reconstruction **conserve une information intrinsèque**.
- Proof of concept, mais le système global doit être **amélioré**.

## **Contributions et Perspectives**

---

Dans cette thèse, nous avons proposé les trois contributions suivantes:

- Un algorithme de clustering collaboratif incrémental permettant une adaptation des clusters aux éventuelles évolutions de la distribution des données.
- Une méthode de pondération automatique des vues externes permettant d'améliorer la qualité des collaborations lors d'un clustering collaboratif.
- L'application du paradigme collaboratif au problème de la reconstruction de données manquantes.

Les apports de la thèse concernent les deux domaines suivants:

- Le clustering collaboratif
  - (article) ICONIP 2017
  - (article) EGC 2018
  - (article) IJCNN 2018
- La reconstruction collaborative
  - (journal, en cours de soumission) KAIS

- Analyse du comportement aux limites de la méthode de clustering collaboratif incrémental.
- Amélioration de chaque module utilisé pour le système de reconstruction collaborative, en particulier les liens permettant d'obtenir les reconstructions intermédiaires.
- Étude théorique et approfondissement du paradigme de reconstruction collaborative: définition des conditions de transférabilité des informations inter-vues, attestation de la qualité des individus reconstruits.



Merci pour votre attention.

Questions ?